실험 2. GPU 최적화: 같은 모델을 더 빨리 돌릴 수 있나

온디바이스 AI 4조 | 2026-11-08 | 장준용 | Kaggle Tesla T4 (torch 2.11) | ImageNet-1K 검증 5만 장 | 재학습 없음

한눈에 보기

- torch.compile과 CUDA Graphs를 같이 쓰면 사진 한 장(τ = 1.0) 추론이 기본 실행 19.1 ms에서 FP32 4.0 ms, FP16 2.3 ms로 줄었다. 각각 4.8배, 8.5배 빨라졌다. 기본 실행에서는 GPU에 명령을 내리는 시간이 계산 시간보다 훨씬 길었다.
- 이렇게 바꾸고 나서야 토큰 제거가 GPU에서도 시간을 줄였다. FP32에서 원래 모델이 3.98 ms, 토큰 제거 Top-K 25%(파인튜닝)가 3.20 ms다. 기본 실행에서는 토큰을 빼도 19.1 → 19.9 ms로 오히려 늘었다.
- 같은 시간을 쓰는 원래 모델과 정확도를 비교하면, 기본 실행에서는 토큰 제거가 2.3%p 손해였다. 최적화 후에는 25%가 +0.13%p(차이 없음), 50%가 +0.23%p(95% 구간 +0.05 ~ +0.43)였다. 손해는 사라졌지만 계산량 기준에서 본 +2.4%p 이득은 사진 한 장씩 처리하는 GPU에서는 아직 시간으로 거의 돌아오지 않는다.
- 사진 32장을 한 번에 처리하면 토큰 25%만 남긴 6H가 전부 계산의 24~27% 시간으로 끝난다. 계산을 줄인 만큼 시간이 준다.
- FP16으로 바꿔도 정확도는 거의 그대로다. 5만 장 중 답이 바뀐 사진은 11~248장이고 전체 정확도 차이는 0.03%p 이하다.

1. 왜 이 실험을 했나

11/3 실험 7에서 토큰 제거 방식으로 파인튜닝한 모델은 같은 계산량의 τ 조절보다 2.4%p 더 정확했다. CPU에서는 시간도 그만큼 줄었다. 그런데 GPU(RTX 4090)에서 사진을 한 장씩 넣으면 시간이 그대로였다. 원래 모델이 5.5 ms, 토큰 제거가 5.7 ms였다(h1_diagnosis.md 실험 5).

그때 세운 설명은 이렇다. PyTorch는 기본적으로 연산 하나마다 CPU가 GPU에 명령을 하나씩 보내는데, ViT를 한 번 돌리면 이런 명령이 수백 개 나간다. 사진 한 장은 계산이 금방 끝나서 GPU가 다음 명령을 기다리는 시간이 더 길다. 그러면 토큰을 빼서 계산을 줄여도 시간은 줄지 않는다.

그래서 세 가지를 확인했다.

1. 명령 내리는 비용을 줄이면 전체가 빨라지나?
2. 그러면 토큰 제거가 GPU에서도 시간을 아끼게 되나?
3. FP16으로 바꿔도 정확도가 유지되나?

2. 무엇을 바꿔 봤나

실행 방식	하는 일
기본 실행 (eager)	연산마다 GPU에 명령을 하나씩 보낸다. 지금까지 모든 측정이 이 방식이었다.
torch.compile	연산 여러 개를 하나로 합쳐 명령 수를 줄인다.
CUDA Graphs	명령 순서를 한 번 녹화해 두고, 다음부터 녹화본을 한 번에 다시 보낸다.
torch.compile + CUDA Graphs	둘 다 쓴다 (torch.compile(mode="reduce-overhead")).

숫자 형식은 FP32(32비트)와 FP16(16비트) 두 가지로 쟀다. FP16에서는 모델 가중치와 입력을 모두 16비트로 바꿨다.

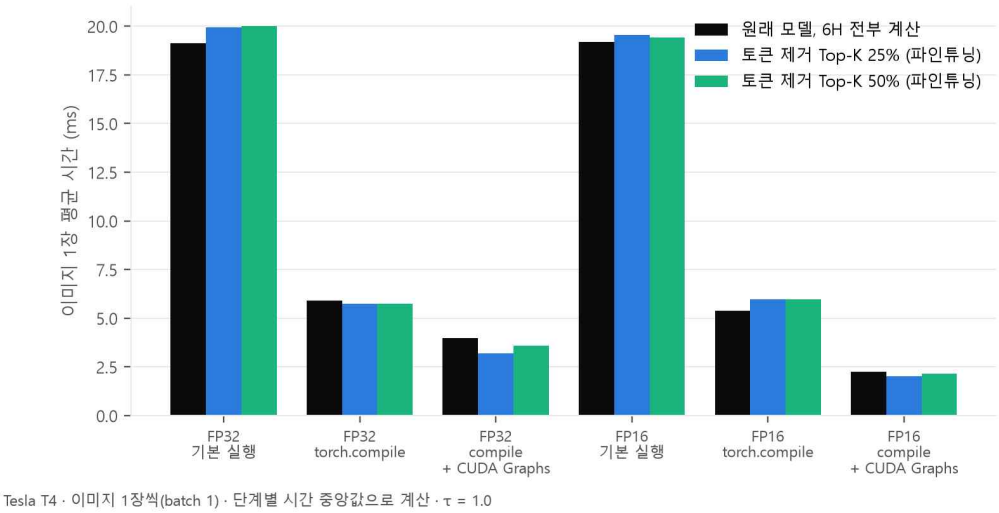
- **측정 방법:** 추론을 단계로 나눠 단계마다 300번 재고 중앙값을 썼다. 단계는 3H, 3H + attention(토큰을 고르려면 3H의 CLS attention을 꺼내야 한다), 6H 전부 계산, 6H 토큰 제거 Top-K 25/50/75%다. 사진 한 장의 평균 시간은 τ = 1.0 기준으로 "3H + (6H로 가는 비율 36%) × 6H"로 계산했다. 토큰 제거일 때는 3H 대신 3H + attention을 넣었다. 전처리와 CPU→GPU 이미지 복사는 뺐다.
- **코드를 두 군데 고쳤다:** CUDA Graphs는 "GPU가 끝날 때까지 CPU가 기다리는" 코드가 있으면 녹화할 수 없다.

- 토큰을 고르던 mask.nonzero()는 남길 토큰 수를 CPU가 알아야 해서 GPU를 기다린다. 크기가 정해진 topk + sort로 바꿨다. 결과(logits)가 원래 코드와 같은지 먼저 확인한다.
- 엔트로피 계산에 쓰는 Categorical은 입력 확률을 검사하면서 GPU를 기다린다. 이 검사를 껐다. 계산값은 바뀌지 않는다. FP16에서는 확률 합이 1에서 조금 어긋나 이 검사에 걸리기도 해서 정확도 평가 코드에서도 껐다.
- **GPU가 T4인 이유:** 문화관 PC(RTX 4090)가 11/5 밤부터 꺼져 있어 Kaggle의 무료 T4에서 쟀다. 그래서 시간 숫자는 11/3의 4090 숫자와 직접 비교할 수 없다. 이 문서의 비교는 모두 같은 T4 안에서 했다. T4에는 TF32가 없어 FP32는 순수 FP32로 계산된다. 정확도도 T4에서 FP32와 FP16을 둘 다 다시 쟀다. FP32 정확도는 4090 결과와 0.01%p 안에서 같다(τ = 1.0 원래 모델 80.30%, 파인튜닝 토큰 제거 25% 78.43%).

3. 결과

3-1. 명령 내리는 비용을 줄이면 빨라지나 → 4.8 ~ 8.5배 빨라진다

단계별 시간, 사진 1장 (ms)	3H	3H + attention	6H 전부	6H 토큰 제거 25%	50%	75%
FP32 기본 실행	13.26	14.02	16.25	16.38	16.58	16.41
FP32 torch.compile	4.19	4.37	4.81	3.85	3.83	4.01
FP32 compile + CUDA Graphs	2.24	2.35	4.85	2.36	3.41	4.03
FP16 기본 실행	13.54	13.62	15.67	16.38	16.07	15.99
FP16 torch.compile	4.02	4.58	3.79	3.89	3.86	3.88
FP16 compile + CUDA Graphs	1.60	1.53	1.83	1.41	1.71	1.78



Tesla T4 · 이미지 1장씩(batch 1) · 단계별 시간 중앙값으로 계산 · τ = 1.0

실행 방식별 사진 한 장 평균 시간

사진 1장 평균 시간, τ = 1.0 (ms)	원래 모델	토큰 제거 Top-K 25%	토큰 제거 Top-K 50%
FP32 기본 실행	19.12	19.94	20.01
FP32 torch.compile	5.92	5.76	5.75
FP32 compile + CUDA Graphs	3.98	3.20	3.58
FP16 기본 실행	19.19	19.54	19.43
FP16 torch.compile	5.39	5.99	5.98
FP16 compile + CUDA Graphs	2.26	2.03	2.14

- 기본 실행에서는 3H만 해도 13 ms인데, compile + CUDA Graphs로는 1.6 ~ 2.2 ms다. 같은 계산이 1/6 ~ 1/8 시간에 끝났으니, 기본 실행 시간의 대부분은 계산이 아니라 명령을 내리는 시간이었다.
- torch.compile만 써도 3배 넘게 빨라진다(19.1 → 5.9 ms). CUDA Graphs를 더하면 FP32 4.0 ms, FP16 2.3 ms까지 내려간다.
- FP16은 기본 실행이나 torch.compile만 쓸 때는 FP32와 비슷하다. 명령 내리는 비용이 계산 비용을

가리기 때문이다. 이 비용을 걷어 낸 compile + CUDA Graphs에서는 FP32보다 43% 빨랐다(3.98 → 2.26 ms).

- torch.compile은 처음 실행할 때 준비 시간이 든다. 사진 한 장 기준으로 단계마다 8 ~ 17초였고 32장을 한 번에 넣는 토큰 제거 단계는 77초, 467초까지 걸렸다. 앱을 켤 때 한 번 드는 비용이다.

3-2. 토큰 제거가 GPU에서도 시간을 아끼게 되나 → 아끼지만, 정확도 이득은 아직 작다

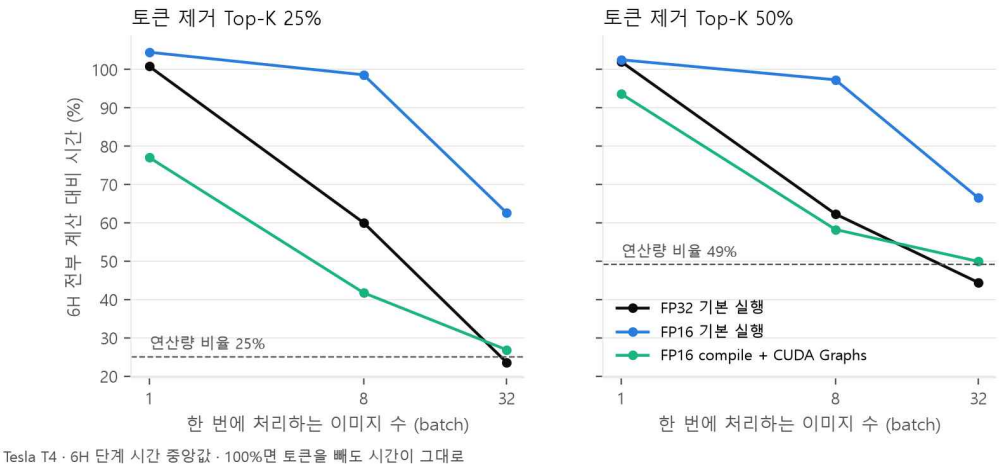
토큰 제거가 "같은 시간"에서도 나은지 보려고, 원래 모델이 토큰 제거와 같은 시간을 쓰도록 6H로 보내는 사진 수를 맞췄다. 엔트로피가 높은 사진부터 6H로 보냈다(11/3의 같은 계산량 비교 방법을 시간에 적용했다). 그다음 사진마다 정답 여부를 짝지어 비교하고 부트스트랩으로 95% 구간을 냈다. 토큰 제거 쪽은 파인튜닝한 모델을 썼다.

같은 시간에서 비교	25%: 원래 모델 → 토큰 제거	차이 (95% 구간)	50%: 원래 모델 → 토큰 제거	차이 (95% 구간)
FP32 기본 실행	80.73% → 78.43%	−2.30 (−2.51 ~ −2.08)	80.77% → 79.67%	−1.10 (−1.27 ~ −0.92)
FP32 torch.compile	79.99% → 78.43%	−1.56 (−1.77 ~ −1.34)	79.97% → 79.67%	−0.30 (−0.48 ~ −0.12)
FP32 compile + CUDA Graphs	78.30% → 78.43%	+0.13 (−0.10 ~ +0.37)	79.43% → 79.67%	+0.23 (+0.05 ~ +0.43)
FP16 기본 실행	80.51% → 78.42%	−2.08 (−2.30 ~ −1.87)	80.46% → 79.65%	−0.81 (−0.98 ~ −0.64)
FP16 torch.compile	81.28% → 78.42%	−2.85 (−3.09 ~ −2.61)	81.27% → 79.65%	−1.61 (−1.81 ~ −1.41)
FP16 compile + CUDA Graphs	78.91% → 78.42%	−0.49 (−0.72 ~ −0.25)	79.64% → 79.65%	+0.01 (−0.16 ~ +0.19)

- 기본 실행에서는 토큰 제거가 2%p 넘게 손해다. 4090에서 본 모습(−2.1 / −0.9%p)과 같다. 토큰을 빼도 시간이 안 줄고 attention을 꺼내는 시간만 늘어서 같은 시간이면 원래 모델이 사진을 더 많이 6H로 보낼 수 있기 때문이다.
- compile + CUDA Graphs에서는 손해가 사라졌다. FP32 50%는 근소하게 앞선다(+0.23%p).
- 그래도 계산량 기준 +2.4%p에 비하면 작다. 이유는 두 가지다.
  - 사진 한 장 시간의 대부분이 3H다. FP16 compile + CUDA Graphs에서 2.26 ms 중 1.60 ms가 3H이고 6H 몫은 0.66 ms뿐이다. 토큰 제거는 이 0.66 ms 안에서만 시간을 줄일 수 있다.
  - 토큰을 25%만 남겨도 6H 시간은 전부 계산의 49%(FP32), 77%(FP16)다. 계산량은 25%로 줄었는데, 사진 한 장으로는 GPU를 다 못 채워 시간은 그만큼 줄지 않는다.
- FP16 torch.compile에서만 토큰 제거가 더 느렸다(5.39 → 5.99 ms). 이 설정에서는 3H + attention이 3H보다 0.56 ms 느렸고 6H는 토큰을 빼도 거의 같았다(3.79 vs 3.89 ms).

3-3. 여러 장을 한 번에 처리하면 → 계산을 줄인 만큼 시간이 준다

6H 시간 (전부 계산 = 100%)	토큰 제거 25%: 1장 / 8장 / 32장	토큰 제거 50%: 1장 / 8장 / 32장
계산량 비율 (이론)	25%	49%
FP32 기본 실행	101% / 60% / 24%	102% / 62% / 44%
FP16 기본 실행	104% / 99% / 63%	103% / 97% / 66%
FP16 compile + CUDA Graphs	77% / 42% / 27%	94% / 58% / 50%



한 번에 처리하는 사진 수에 따른 토큰 제거의 6H 시간

- 32장을 한 번에 넣으면 GPU가 계산으로 꽉 차서 토큰 25%만 남긴 6H가 24 ~ 27% 시간에 끝난다. 계산량 비율(25%)과 거의 같다.
- FP16 기본 실행은 32장에서도 63%다. FP16은 계산이 빨라서 32장으로도 명령 내리는 비용이 아직 크다. compile + CUDA Graphs를 더하면 27%로 내려간다.
- 서버처럼 사진을 모아서 처리할 수 있다면 토큰 제거의 계산 절약이 GPU에서도 시간 절약이 된다.

3-4. FP16으로 바꿔도 정확도가 유지되나 → 유지된다

전체 정확도 (T4)	3H만	τ = 1.0, 6H 전부	τ = 1.0, 토큰 제거 25%	τ = 1.0, 토큰 제거 50%
원래 모델 FP32	73.54%	80.30%	73.81%	78.60%
원래 모델 FP16	73.54%	80.31%	73.79%	78.63%
파인튜닝 모델 FP32	73.60%	79.98%	78.43%	79.67%
파인튜닝 모델 FP16	73.60%	79.98%	78.42%	79.65%

FP32 → FP16에서 답이 바뀐 사진 (5만 장 중)	6H로 보낼지 판단	3H	6H 전부	토큰 제거 25%	토큰 제거 50%
원래 모델	32	36	21	248	96
파인튜닝 모델	26	28	11	125	75

- 정확도 차이는 0.03%p 이하다. 바뀐 사진들도 맞던 게 틀리고 틀리던 게 맞아서 서로 상쇄된다.
- 토큰 제거에서 바뀐 사진이 조금 더 많다. 3H attention 값이 조금만 달라져도 고르는 토큰이 바뀌기 때문으로 보인다. 파인튜닝 모델에서는 그 수가 절반으로 줄었다.

4. 정리

- 이번 실험에서 GPU 시간을 가장 크게 줄인 건 토큰 제거가 아니라 실행 방식이었다. torch.compile + CUDA Graphs는 코드 몇 줄로 시간을 4.8 ~ 8.5배 줄였고 FP16은 정확도를 거의 잃지 않았다.
- 토큰 제거는 실행 방식을 바꾼 뒤에야 GPU에서 시간을 줄였다. 사진 한 장씩 처리하면 이득이 작다(같은 시간에서 0 ~ +0.2%p). 여러 장을 모으면 계산을 줄인 만큼 시간이 준다.
- 11/3 결과와 합치면 이렇다. CPU(휴대폰과 비슷한 환경)에서는 토큰 제거가 그대로 시간 절약이 된다. GPU에서는 실행 방식을 먼저 최적화해야 하고 사진을 모아 처리할 때 효과가 크다.

5. 한계

- T4 한 종류에서만 쟀다. 4090 결과와 직접 비교할 수 없고 실제 휴대폰이나 Jetson 같은 기기는 재지 않았다. Kaggle 서버의 CPU가 느린 편이라 기본 실행에서 명령 내리는 비용이 일반 PC보다 크게 나왔을 수 있다. 4090 PC에서 기본 실행 3H는 약 4 ms였다.
- CUDA Graphs만 따로 쓴 경우는 모든 단계에서 녹화에 실패했다(Cannot copy between CPU and CUDA tensors during CUDA graph capture). 모델 코드가 CPU 텐서를 쓰지 않는 것은 확인했

다. GPU 연산 하나가 내부에서 복사를 하는 것으로 보이지만 어느 연산인지는 아직 못 찾았다. torch.compile을 거치면 녹화가 된다.

- 시간은 단계별 중앙값을 더한 추정치다. 실제로 사진마다 6H로 보낼지 정하려면 엔트로피를 CPU로 읽어야 하는데, 이때 GPU를 기다리는 시간은 포함하지 않았다.
- 파인튜닝 모델은 하나(시드 42)뿐이다.